



ROCM 在 RISC-V 上的适配情况

用户空间软件构建

报告人：陈璇

邮箱：sakura286@outlook.com

日期：2025.09.10

创新求实·永攀一流

地址：北京市海淀区中关村南四街4号中国科学院软件园区

目录

-  1. ROCm 支持情况概述
-  2. 用户空间软件栈构建与移植
-  3. 内核部分简要概括

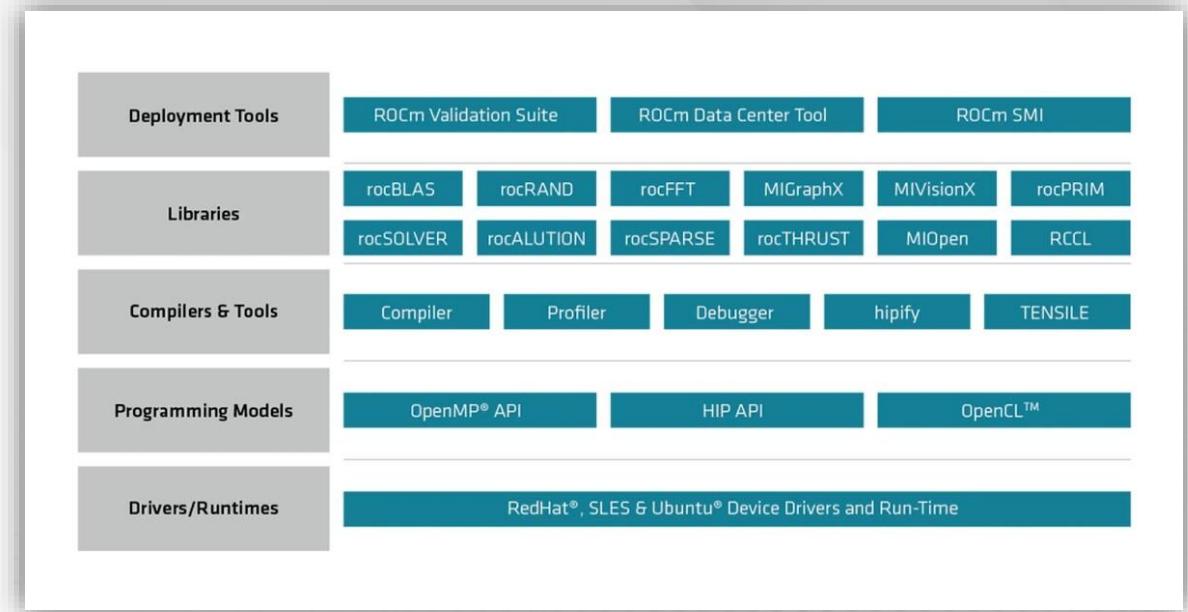
第1部分

ROCM 支持情况概述



ROCM (Radeon Open Compute Platform) 是一个开放式软件栈，包含多种驱动程序、开发工具和 API，可为从底层内核到最终用户应用的 GPU 编程提供助力。ROCM 已针对生成式 AI 和 HPC 应用进行了优化，而且能够轻松将现有代码迁移到 ROCM 软件。

简要来说，ROCM 是 AMD 提供的 GPU 计算平台，类比/对标的是 NVIDIA 的 CUDA。而且 ROCM 是开源软件栈，用户有适配至不同 SOC/OS 的可能。



GPU支持情况

- RDNA 架构的中高端的 Radeon (Pro) 显卡，及CDNA系列的 AMD Instinct 显卡 [1]

CPU支持情况

- 根据 AMD 官方提供的构建脚本，官方支持的指令集架构为 **x86** [2]
- Debian ROCm 支持的指令集架构为 amd64 arm64 与 ppc64el [3]
- 理论上，支持 **PCIe Atoms** 的现代 CPU 都可以运行

[1] <https://rocm.docs.amd.com/projects/install-on-linux/en/latest/reference/system-requirements.html>

[2] https://github.com/ROCM/ROCM/blob/05a66f75fea71fe19ba29f694c7c22854187e334/tools/rocm-build/build_lightning.sh#L375

[3] <https://buildd.debian.org/status/package.php?p=rocblas&suite=sid>

llama.cpp

ROCM Libraries

ROCM System

RevyOS(vendor kernel 6.16)

SG2044 + W7800

目前，RevyOS 小队在 SG2044 上，使用 Radeon Pro W7800 48GB 显卡成功运行**基于 ROCm 6.4.3 后端的 llama.cpp** [1]

[1] <https://zhuanlan.zhihu.com/p/1928513776661038179>

card	model	size	params	test	t/s
W7800 48GB	llama 70B Q4_K - Medium	39.59 GiB	70.55 B	pp512	236.55 ± 0.22
W7800 48GB	llama 70B Q4_K - Medium	39.59 GiB	70.55 B	tg128	9.71 ± 0.11
W7800 48GB	llama 8B Q4_K - Medium	4.58 GiB	8.03 B	pp512	2043.44 ± 5.71
W7800 48GB	llama 8B Q4_K - Medium	4.58 GiB	8.03 B	tg128	63.72 ± 0.10
W7800 48GB	qwen2 1.5B Q4_K - Medium	1.04 GiB	1.78 B	pp512	7300.93 ± 61.38
W7800 48GB	qwen2 1.5B Q4_K - Medium	1.04 GiB	1.78 B	tg128	94.32 ± 0.06

第2部分

用户空间软件栈构建与移植



添加 RISC-V 的入口

RISC-V 目前并非官方支持架构，所以要在检测 arch 时仿照其他架构添加相应的入口

见 *rocm-llvm*、*rocm-hip-on-rocclr* 仓库

路径修复

官方仓库的默认产物路径不符合发行版行为

opt/rocm	->	/usr or /opt/rocm-\${ROCM_VERSION}
lib/llvm/bin	->	bin
amdclang	->	clang

见 *rocm-tensile*、*rocm-rocblas* 仓库

编译参数

`-DGPU_TARGETS="gfx908:xnack-;gfx90a:xnack-
;gfx90a:xnack+;gfx940;gfx941;gfx942;gfx1030;gfx1100"`

在编译**数学库及 rccl** 等库时，这是 hipcc 生成 GPU 代码的默认目标，但因为 Linux 上 AMD 独显并不支持 xnack^[1]，所以 xnack 部分可以去掉

减少 GPU 代码生成目标可以显著减少编译时间以及产物大小，尤其是在编译 test 及 benchmark 的情况下。

例如，对于 7900XTX 来说，仅需 `-DGPU_TARGETS="gfx1100"`

[1] <https://niconiconi.neocities.org/tech-notes/xnack-on-amd-gpus/>



指令替换

```
fence.tso -> fence.rw.rw  
_mm_sfence(); -> asm volatile("fence w,w" :::"memory"); [1]  
_mm_mfence(); -> asm volatile("fence rw,rw" :::"memory"); [2]  
_mm_pause(); -> asm volatile(".insn 0x0100000f" :::"memory"); [3]
```

V 拓展的一点小坑

如果目标平台不支持V，则编译llama.cpp时需要 `-DGGML_RVV=OFF` 来关闭以避免运行时报错 [4]

[1] <https://elixir.bootlin.com/linux/v6.12.6/source/tools/arch/riscv/include/asm/barrier.h>

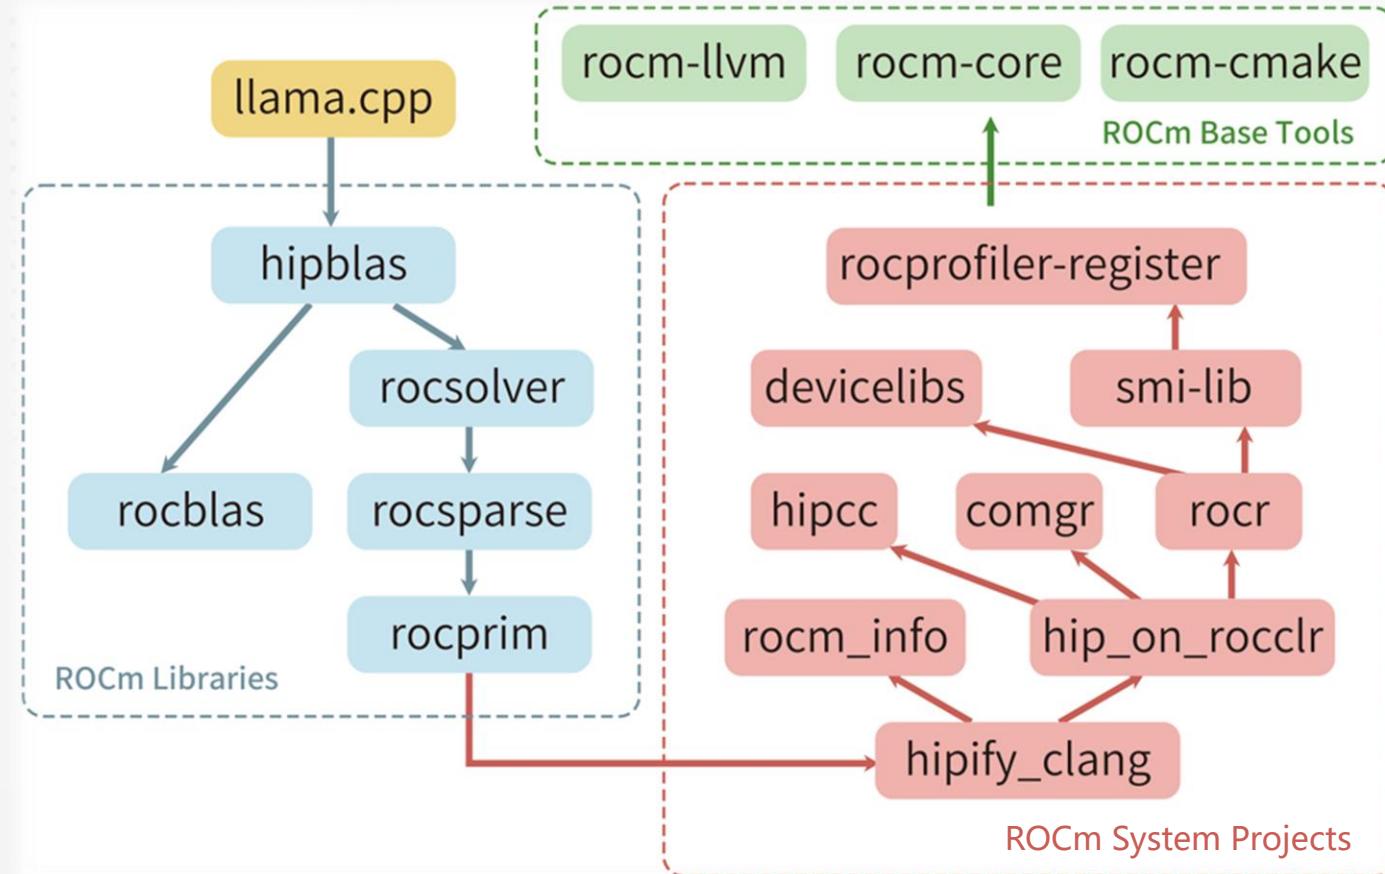
<https://elixir.bootlin.com/linux/v6.12.6/source/arch/x86/um/asm/barrier.h>

[2] RISC-V Memory Consistency Model Specification (DRAFT) - 2.6 Code Porting Guidelines

[3] <https://gcc.gnu.org/pipermail/gcc-patches/2023-August/627546.html>

[4] <https://github.com/ggml-org/llama.cpp/blob/86587da03bd78df8f4e7d8b111a0c1d2494d6ed0/ggml/CMakeLists.txt#L131>

构建&移植 3: llama.cpp 依赖链条



更详细的依赖情况, 请查看 revyos-rocm github 组织下仓库的 debian/control

源码

<https://github.com/orgs/revyos-rocm/repositories>

构建脚本为 debian/rules 文件

构建补丁在 debian/patches 目录下

二进制软件仓库

<https://fast-mirror.isrc.ac.cn/revyos/trixie/revyos-rocm/>

第3部分

内核部分简要概括





RevyOS SG2044 6.16 内核源码

<https://github.com/revyos/sg2044-vendor-kernel>

mmap() 补丁

https://lore.kernel.org/all/20250707193411886Kc-TWknP0PER2_sEg-byb@zte.com.cn/

感谢观看

本 ppt 获取地址：

<https://github.com/Sakura286/TmpShare/20250910-120000-ROCM-user.pdf>